# 欢迎大家选修本课程!

# 数据结构与算法



#### 宋国杰

北京大学信息科学技术学院

# 欢迎加盟我的团队!

- →研究:数据挖掘、机器学习与人工智能(基础) 社会网络、智能交通系统等(应用)
- ▶项目: 主持国家863、科技支撑计划、国家自然基金、 北京自然基金等(纵向); NEC研究院、中兴通信、 北京高速、安徽高速、山西高速、国家电网(横向)
- ▶成果: 国际顶级期刊和会议论文, IEEE Transaction on (TKDE、TPDS、TITS)等, KDD、AAAI等 中国公路学会科学技术奖(一等奖)2项等

### 关于本课程

#### 《数据结构与算法》

- >逻辑结构
  - ▶ 图 ⊇ 树 ⊇ 线性
- > 存储结构
  - ▶ 顺序方法、链接方法
  - ★ 索引方法、散列方法

- ≻运算
  - → 增、删、改等简单运算
  - ▶ 遍历、排序等复杂运算

时间复杂性

空间复杂性

## 课程内容

第1章 概论

第8章 内排序

第2章 线性表

第9章 外排序

第3章 栈和队列

第10章 检索

第4章 字符串

第11章 索引


第5章 二叉树

第12章 高级数据结构

第6章 树

第7章图

# 出行导航问题



### 课程地位

#### Web信息处理

队列、图、字符、矩阵散列、排序、索引、 检索

#### 数据库概论

线性表、多链表、排序及B+索引树

概率统计

#### 人工智能

广义表、集合、搜索树及各种有向图

#### 操作系统

队列、存储管理表、排序及目录树

数据结构与算法实习

数据结构与算法

程序设计实习

计算概论

#### 图形图像

队列、栈、图、矩阵、空间索引树、检索

#### 编译原理

字符串、栈、散列表及语法树

算法分析与设计

集合论与图论

#### 课程特点

>基础性

>挑战性

>理论性

>实践性

#### 教学目标

- > 数据组织和算法分析能力
  - ◆ 合理的组织数据、表示数据和处理数据
- > 抽象能力
  - ➡问题→数据→算法
- > 算法的设计与分析
- > 编程能力
  - ➡提高程序设计的质量

### 教学要求

#### >课程讲授

▶ 讲核心、重点和难点内容,因此需要同学们预习、自学

#### >诚信作业

▶ 提倡讨论, 但严禁抄袭

#### >加强训练

**▶有效反馈** 

## 书面作业提交要求

- > 写学号、名字
- 》每次作业,都在纯文本(或PDF)中写上"<u>我保证没有抄袭他人作业</u>"的诚实保证。否则,计零分或根据抄袭情况倒扣分。

#### 课程评估

#### > 课程作业

- ▶ 书面作业,分析证明类题目
- **→ MOOC作业** 
  - 概念测试、POJ算法填空、POJ算法设计与实现
- ▶ 考核方式(作业50% +考试50%)
  - ▶ 平时作业+考勤 20%
  - → MOOC作业 30%
  - ▶ POJ考试 20%
  - ⇒ 期末考试 30%

## 教材

》张铭,王腾蛟,赵海燕,《数据结构与算法》,高等教育出版社,2008年6月。——普通高等教育"十一五"国家级规划教材

》张铭、赵海燕、王腾蛟,《数据结构与 算法——学习指导与习题解析》,高等 教育出版社,2005年10月。——"十五" 国家级规划教材配套参考书





### 课程网站

http://course.pku.edu.cn/webapps/login/



# 助教信息

姓名	手机	邮箱			
杜思臻	15201645119	dusizhen@126.com			
刘丹萌	18707191855	304680632@qq.com			
李晨	18911840601	57577743@qq.com			
焦振宇	15302182199	j.shower@163.com			
李肯	15650709373	1401214344@pku.edu.cn			

# 第一章 概论

#### 1. 数据结构


- >数据结构(Data Structure)
  - →涉及数据之间的逻辑关系、数据在计算机中的<u>存储</u>表示和在这种结构上的一组能执行的操作(运算) 三个方面。
- >三要素
  - →逻辑结构
  - ▶存储(物理)结构
  - ▶运算

### 逻辑结构

- >逻辑结构(Logical Structure)
  - ▶ 具体问题的数学抽象,反映事物组成和逻辑关系
- > 逻辑结构的表示
  - ▶ 用一组数据(表示为结点集合K),及数据间的二元关系 (<u>关系</u>集合R)表示:(K,R)
    - K由有限个结点组成,代表一个或一组有明确结构的数据
    - R是定义在集合K上的一组关系,每个关系 r∈R都是K×K上的二 元关系,描述结点间的逻辑关系

## 举例

- > 家族成员数据结构
  - ▶ 把每个成员个体作为数据结点,而全部人员组成结点集K
  - ⇒ 家族中各类亲属关系就是一组关系R
    - 其中如母子关系r、兄弟关系r\*、和妯娌关系r'等



## 节点的类型

- > 基本数据类型
  - ▶ 整数类型(integer)、实数类型(real)、字符类型(char)和指 针类型(pointer)
- > 复合数据类型
  - ▶ 由基本数据类型组合而成的数据结构类型。
    - 如数组、结构类型等
  - ▶ 复合数据类型本身,又可参与定义更为复杂的结点类型
- ▶ 结点的类型可以根据应用的需要来灵活定义

## 结构(关系)的分类

- ▶逻辑结构(K,R)的分类,<u>讨论重点在关系集R上</u>
- > 用R的性质来刻划数据结构的特点,并进行分类

  - → 线性结构 (linear structure)
  - → 树型结构 (tree structure)
  - ▶ 图结构 (graph structure)

#### 线性结构


▶亦称'<u>前驱关系</u>'。关系r是有向的,且满足 全序性和单索性等约束条件

- ◆全序性: 全部结点两两<u>皆可比较前后</u>
- ▶ 单索性: 每个结点都存在唯一一个前驱和后继结点

0	1	2	3	4	5	• • •	N-2	N-1	N

#### 树型结构

- ▶亦称<u>层次结构</u>,每个结点可有<u>多于1个'直</u>接下级',但只有<u>唯一的'直接上级</u>'
- ▶最高层结点称为根 (root)结点,无父结点




#### 图型结构

- ▶图结构有时称为结点互联的<u>网络结构</u>
  - **▶** 交通网、因特网、社会网络等
- >对于图结构的<u>关系r没有加任何约束</u>
- ▶ 树型结构和图型结构的基本区别是"<u>每个结点</u> 是否仅仅属于一个直接上级"。
- ▶线性结构和树型结构的基本区别是"<u>每个结点</u> 是否仅仅有一个直接的后继"


#### Network: Facebook Social Graph



#### Network: Connections between political blogs




#### Network: Information network



Citation networks and Maps of science


#### Network: Knowledge network



Understand how humans navigate Wikipedia


Get an idea of how people connect concepts

#### Network: Organization




9/11 terrorist network

#### **Network: Economy**




Bio-tech companies


#### **Network: Brain**



Human brain has between 10-100 billion neurons

#### **Network: Biology**





#### **Protein-Protein Interaction Networks:**

Nodes: Proteins


Edges: 'physical' interactions

#### Metabolic networks:

Nodes: Metabolites and enzymes

**Edges: Chemical reactions** 

#### **Network: Food Webs**



### 结点和结构(关系)

- <u>自顶向下</u>的逻辑结构分析设计方法
  - ▶数据结构的设计可以是一层一层地进行的
  - ◆先明确数据结点,及其主要关系r
  - ▶ 在分析关系r时,也要分析其数据结点的<u>数据类型</u>
  - ▶如果数据结点的<u>逻辑结构比较复杂</u>,那么把它作为 下一个层次,<u>再分析下一层次</u>的逻辑结构

#### 存储结构

- >数据的存储结构(Storage Structure)
  - ➡ 也称物理结构 (Physical Structure)
  - ▶ 是逻辑结构在计算机中的物理存储表示
- > 计算机主存储器
  - ➡空间相邻: 其存储空间提供了一种具有非负整数地址编码的、存储空间相邻的单元集合,其基本的存储单元是字节
  - ▶随机访问: 计算机的指令具有按地址随机访问存储空间内任意单元的能力,访问不同地址所需的访问时间基本相同

# 存储结构(Con.)

- > 存储结构建立一种逻辑结构到物理结构的映射
  - → 逻辑结点K到物理空间M的映射( $K\rightarrow M$ ): 对于每一个结点 $j\in K$ 都对应一个唯一的存储区域 $c\in M$ 。
  - ▶ 逻辑关系到物理关系的映射:每一关系元组(j₁,j₂)
    ∈r(其中j₁,j₂∈K是结点),亦即j₁,j₂的逻辑关系映射为存储单元的地址顺序关系(或指针地址指向关系)
- > 四种基本存储映射方法
  - ▶顺序、链接、索引、散列


### 顺序方法

#### ▶ 顺序存储

- ◆ 结点按<u>地址相邻关系</u>顺序存储,结点间逻辑关系用存储单 元的自然顺序关系来表达
- ▶ 数组是顺序存储法的具体实例
- > 顺序存储是紧凑存储结构
  - ▶ 紧凑指存储空间除存储有用数据外,不存储其他附加信息
  - → 存储密度:存储结构所存储'有用数据'和该结构(包括 附加信息)整个存储空间大小之比

### 举例

> 顺序存储结构




> 支持整数编码访问

Moo	M <sub>01</sub>	M <sub>02</sub>
M <sub>10</sub>	<b>M</b> 11	M <sub>12</sub>
M <sub>20</sub>	M <sub>21</sub>	M <sub>22</sub>

M[i][j]=M[0][0]+(k\*i+j)\*(元素尺寸)

### 链接方法

- > 链接法
  - ▶ 利用存储结构中附加指针字段来表示两个结点间逻辑关系
- >任意的逻辑关系r,都可以使用这种指针地址来表达。
  - 一般的做法是将数据结点分为两部分:
  - ▶ 数据字段: 存放结点本身的数据
  - ▶ <u>指针字段:</u> 存放指针,链接到某个后继结点,指向它的存储单元的开始地址。
  - ▶ 多个相关结点的依次链接就会形成链索




### 链接方法(Con.)

- ▶优点:增删容易
  - ▶顺序方法对于经常增、删结点情形,往往遇到困难
  - ◆链接方法结合动态存储可以解决这些复杂的问题

- ▶缺点: 定位困难
  - ▶访问结点必须知道该结点的指针
  - ◆否则需要沿着链接指针逐个搜索,花费时间较大

### 索引方法

- > 是顺序存储法的一种推广
- ➤索引方法是要建造一个由整数域 Z 映射到存储地址 域D 的函数Y: Z→D, 把结点的整数索引值 z∈Z映 射到结点的存储地址 d∈D。Y称为索引函数



### 目 录。


数据	结构	与算法	t实验教程	i⊬
内容	提要	Ę		ii∻
前	言			iii⊬
目	录			iv↔
第1	章	数据组	· - - - - - - - - - - - - - - - - - - -	1
	1.1	"数据结构与算法"的理论体系		
		1.1.1	课程的基本定位	2↔
		1.1.2	知识体系	3↔
	1.2	"数据	结构与算法"学习重点	6⊬
		1.2.1	概论	6⊬
		1.2.2	线性表	7←
		1.2.3	栈与队列	9←
		1.2.4	字符串	10
		1.2.5	二叉树	114
		1.2.6	树	134
		1.2.7	图	14+
		1.2.8	内排序	16
		1.2.9	文件与外排序	18+
		1.2.10	检索	19+

### 散列方法

- ▶ 散列是索引方法的延伸和扩展
- **▶ 散列函数:将关键码 s 映射到非负整数 z**

 $h: S \rightarrow Z$ 

对任意的  $s \in S$  , 散列函数 h(s)=z ,  $z \in Z$ 



### 小结

- > 数据结构
  - → 逻辑结构
    - 节点
      - 基本数据类型整数、实数、布尔、字符,指针
      - 复合数据类型
    - 结构(关系)
      - 线性结构
      - 树型结构
      - 图型结构

- ▶ 存储结构
  - 顺序的方法
  - 链接的方法
  - 索引的方法
  - 散列的方法
- ▶ 数据运算

# 抽象数据类型(ADT)

- > 抽象问题得到解决, 同类具体问题都可得到解
- > ADT是对多种可能的结构和实现的抽象
- ▶ 模块化思想的发展,提供了抽象数据类型的实现手段,简称ADT (Abstract Data Type)
  - ▶ 可以看作是定义了一组操作的一个抽象模型
- 一个抽象数据类型要包括哪些操作,这一点由设计者根据需要确定

# 抽象数据类型(续)

- 》用数学方法定义<u>对象集合和运算集合</u>,仅通过运算的性质刻画数据对象,而独立于计算机中可能的表示方法
- ▶目的在于<u>隐藏运算实现的细节和内部数据结构</u>

### 抽象数据类型(续)

>抽象数据类型由

<数据对象,数据关系,数据操作>

三个不可分割的部分组成的三元组:

ADT抽象数据类型名{

数据对象D:<数据对象的定义>

数据关系S: <数据关系的定义>

数据操作P: <基本操作的定义>

}ADT抽象数据类型名

### ADT示例

```
template<class Type>
```

```
class className{
```

```
private: //数据结构的取值类型与取值空间
Type dataList; //私有变量,存储向量元素
...
public: //运算集
methodName(); //定义对数据的操作
...
```

### 2. 算法

### 问题 —— 算法 —— 程序

目标:问题求解

- ▶ 问题 ( problem ) 一个函数
  - · 从输入到输出的一种映射
- > 算法 (algorithm) 一种方法
  - 对特定问题求解过程的描述,是指令的有限序列
- > 程序 ( program )
  - · 是算法在计算机程序设计语言中的实现

# 数据结构 + 算法 = ?

- ➤ Pascal之父、结构化程序设计的先驱Niklaus Wirth最著名的一本书,叫作《算法+数据结构=程序》
- >程序设计的实质
  - ▶ 为计算机处理问题编制一组"指令"
- > 需要解决两个问题: 算法和数据结构
  - ▶ 数据结构=问题的数学模型
  - ▶ 算法=处理问题的策略

# "算法+数据结构 = 程序"

- >表达了算法与数据结构的联系及其在程序 中的地位
  - ▶程序: 采用特定<u>逻辑结构</u>和<u>存储表示</u>的数据 基础上,算法的实现描述
  - ▶算法与数据结构是程序设计中相辅相成、不可分割的两个方面

### 算法的性质

- > 通用性
  - ▶ 对参数化输入进行问题求解,保证计算结果的正确性
- > 有效性
  - **⇒** 算法是有限条指令组成的指令序列,即由一系列具体步骤组成
- > 确定性
  - **⇒** 算法描述中的下一步应执行的步骤必须明确
- > 有穷性
  - **▶** 算法的执行必须在有限步内结束
  - ▶ 换句话说,算法不能含有死循环

### 算法分类

算法设计与算法分析是计算机科学的核心问题

- > 穷举法(百钱买百鸡)——万能,低效
  - ▶ 避免穷举测试
- ▶回溯(迷宫、八皇后)、搜索(DFS, BFS)
  - ▶ 跳过无解分支、最优化问题的通法
- > 递归分治(二分检索、快速排序、分治排序)
  - → 子结构不重复
  - ▶ 分、治、合


# 算法分类(续)

- ▶贪心法(Greedy)
  - ▶ 最优子结构——最优解
  - ▶ 否则,只是快速得到次优解
- ▶ 动态规划 (Floyd算法)
  - ——自底向上,利用中间结果,迅速构造
    - → 最优子结构、重复子结构、无后效性
    - ▶ 搜索中分支定界的特例
    - ➡ 空间换时间

### 3、算法分析

- ▶算法分析是对一个算法需要多少<u>计算时间和</u> 存储空间作定量分析。
- ▶时间资源和空间资源之间<u>采取折衷</u>
- >可以通过算法分析,判断所提出的算法是否

符合现实情况



### 算法复杂性度量

- 一不能用诸如微秒、纳秒这样的真实时间单位
  - ▶ 环境不同而不同
    - -一个运行在巨型机上的算法若放在PC机会慢很多, 反之亦然
  - ➡ 语言不同而不同
    - C vs LISP
  - ▶ 可扩展性的不同
    - 两个不同的算法也许在输入规模为100时表现不相上下, 而在输入规模扩大10倍后却表现迥异

# 算法复杂性度量(续)

- ▶重要的不是具体的时间,而是算法复杂性与<u>输</u> 入数据规模(N)之间的关系
  - ▶ 例如,对于排序算法来说,输入规模一般就是待排序元素的个数。
- ▶即对应输入规模n的所需 <u>"基本操作(B)"</u>的数 来描述时间效率,与被操作的具体数值无关
  - ➡ 通常是算法最内层循环中最费时的操作

### 示例

> 下面是一段对数组中的各个元素求和的代码:

```
for (i = sum = 0; i<n; i++)
sum += a[i];
```

- ▶ 数据规模: n
- >基本操作: 赋值运算
  - ▶ 在循环开始之前有两次赋值,分别对 i 和对sum进行;
  - → 循环进行了n次,每次循环中执行两次赋值,分别对 sum和对 i 进行更新操作;
  - → 总共有f(n)=2 + 2n次赋值操作

### 分析框架: 增长趋势

### > 增长次数

→ 小规模输入在运行时间上的差别不足以将高效的算法和 低效的算法区分开来。


对于算法分析具有重要意义的函数值(有些是近似值)

n	log₂n	n	n log₂n	n²	n <sup>3</sup>	2 <sup>n</sup>	n!
10	3.3	10 <sup>1</sup>	3.3·10 <sup>1</sup>	10 <sup>2</sup>	10 <sup>3</sup>	10 <sup>3</sup>	$3.6 \cdot 10^6$
$10^{2}$	6.6	$10^2$	$6.6 \cdot 10^2$	$10^4$	$10^6$	$1.3 \cdot 10^{30}$	$9.3 \cdot 10^{157}$
$10^{3}$	10	$10^{3}$	$1.0 \cdot 10^4$	$10^{6}$	10°		
$10^{4}$	13	$10^4$	$1.3 \cdot 10^5$	$10^8$	10 <sup>12</sup>		
10 <sup>5</sup>	17	10 <sup>5</sup>	$1.7 \cdot 10^6$	$10^{10}$	$10^{15}$		
$10^{6}$	20	$10^{6}$	$2.0 \cdot 10^7$	1012	$10^{18}$		

#### 一个需要指数级操作次数的算法只能用来解决规模非常小的问题

# 常用函数的增长趋势

### 增长率函数曲线




### 算法的渐进分析

$$f(n) = n^2 + 100n + \log_{10} n + 1000$$

- > 算法分析就是要估计,当数据规模 n逐步增大时, 资源开销f(n)的增长趋势
- 》从数量级大小的比较来考虑,当n增大到一定值以后,资源开销的计算公式中影响最大的就是n的幂次最高的项,其他的常数项和低幂次项均可忽略。

## 大O表示法

> 定义1: 如果存在正数c和n0,使得对任意的n≥n0,都有



### 大O表示法的性质

- > 若符号a是不依赖于n的任意常数
  - 如果函数 f(n) 是O(g(n))的, g(n)是O(h(n)), 那么f(n)是O(h(n))的;
  - 如果函数f(n)是O(h(n))的, g(n)是O(h(n)), 那么f(n) + g(n) 是O(h(n))的;
  - ▶ 函数an<sup>k</sup>是O(n<sup>k</sup>)的,a不依赖于n;
  - ⇒ 若f(n) = cg(n),则f(n) 是O(g(n))的
  - → 对于任何正数a和b,且b≠1,函数log<sub>a</sub>n是O(log<sub>b</sub>n)的。即, 任何对数函数无论底数为何,都具有相同的增长率
  - → 对任何正数 a≠1,都有log<sub>a</sub>n 是O(lg n)的,其中lg n = log<sub>2</sub>n


### 大O表示法的运算规则

- <u>加法规则</u>:  $f_1(n)+f_2(n)=O(\max(f_1(n),f_2(n)))$ 
  - ▶ 顺序结构, if 结构, switch结构

- ightharpoonup 乘法规则:  $f_1(n) f_2(n) = O(f_1(n) f_2(n))$ 
  - → for, while, do-while结构

# Ω(Omega)表示法

> 定义2: 如果存在正数c和n0,使得对所有的n≥n0,都有




## Θ(Theta)表示法

- > 当上、下限相同时则可用 Θ表示法。
- 》定义3:如果一个函数既在集合O(g(n))中又在集合 $\Omega(g(n))$ 中,则称其为O(g(n))。即存在正常数 $c_1, c_2$ ,以及正整数 $n_0$ ,使得对于任意的正整数n > n0,有下列两不等式同时成立:

$$n^2+3n+2 \in \Theta$$
  $(n^2)$ 

$$n(n-1)/2 \in \Theta(n^2)$$

$$4n^2+5 \in \Theta(n^2)$$



### 算法分析示例(1)

> 依次求出给定数组的所有子数组中各元素之和:

- > 循环开始前,有1次对i的赋值操作。
- 外层循环共进行n次,每个循环中包含一个内层循环,以及对i, j, sum分别进行赋值操作;
  - → 每个内层循环执行2个赋值操作,分别更新sum和j; 共执行i次 (i=1,2,...,n-1)。
- > 整个程序总共执行的赋值操作为:

$$1+3n+\sum_{i=1}^{n-1}2i=1+3n+2(1+2+....n-1)=1+3n+n(n-1)=O(n)+O(n^2)=O(n^2)$$

### 算法分析示例(2)

若只对每个子数组的前5个元素求和,则相应的代码可采用下面的方式:

```
for ( i=4; i<n; i++)

for (j = i-3, sum = a[i-4]; j <= i; j++)

sum += a[j];
```

- ▶ 外层循环进行n-4次
- ▶ 对每个i而言,内层循环只执行4次,每次的操作次数和i的 大小无关: 11次赋值操作
- ▶ 整个代码总共进行 1 + 11\*(n-4) = O(n)次
- > 看似双重循环, 其实线性时间

### 最坏、最好、和平均情况

- > 算法分析受条件分支的影响

  - → 分支走向又受輸入数据取值的影响,因此很多算法都无法得出独立于输入数据的渐进估计
- >估计方法
  - →最坏情况估计
  - →最好情况估计
  - → 平均情况估计

### 平均情况下的复杂性分析

- ▶平均情况下的算法复杂度分析,要考虑算法的所有的 输入情况,确定每种情况下的输入数目
- > 简单情况下,需要考虑每种输入情况的概率

$$C_{avg} = \sum_{i} p(input_{i}) steps(input_{i})$$

p(input<sub>i</sub>)为第i 种输入的出现概率, steps(input<sub>i</sub>)为算法处理第i种输入时所需的基本操作数目。

# 复杂性分析(Con.)

》对于时间开销,一般不注意算法的'最好估计'。特别是处理应急事件,计算机系统必须在规定的响应时间内做完紧急事件处理。这时,最坏估计是唯一的选择

▶对于多数算法而言,最坏情况和平均情况估计,它们的时间开销的公式虽然不同,但是往往只是常数因子大小的区别,或者常数项的大小区别。因此不会影响渐进分析的增长率函数估计

# 时间和空间的折衷

- > 空间开销也可以实行类似的渐进分析方法
- > 静态存储结构
  - **➡空间开销估计往往容易**
- > 动态存储结构
  - **▶**算法运行过程中会有数量级地增大或缩小
  - ▶ 这种情况的空间开销的分析和估计是十分必要的

- > 时空折衷(Trade-off between time and space)
  - →空间换时间: 为改善算法的时间开销,可通过增大空间开销而设计出时间开销小的算法
  - ▶时间换空间:为缩小算法的空间开销,通过增大时间开销来换取存储空间的节省

### 总结

- >学完了本章, 你达到下述要求
  - ▶数据结构的定义
  - →抽象数据类型
  - **▶**算法的特性及分类
  - **▶**算法的效率度量



# 再见…

#### 联系信息:

电子邮件: gjsong@pku.edu.cn

电 话: 62754785

办公地点: 理科2号楼2307室